Aprendizaje por refuerzo

Resumen

Antonio Manjavacas

manjavacas@ugr.es

Contenidos

Visión general

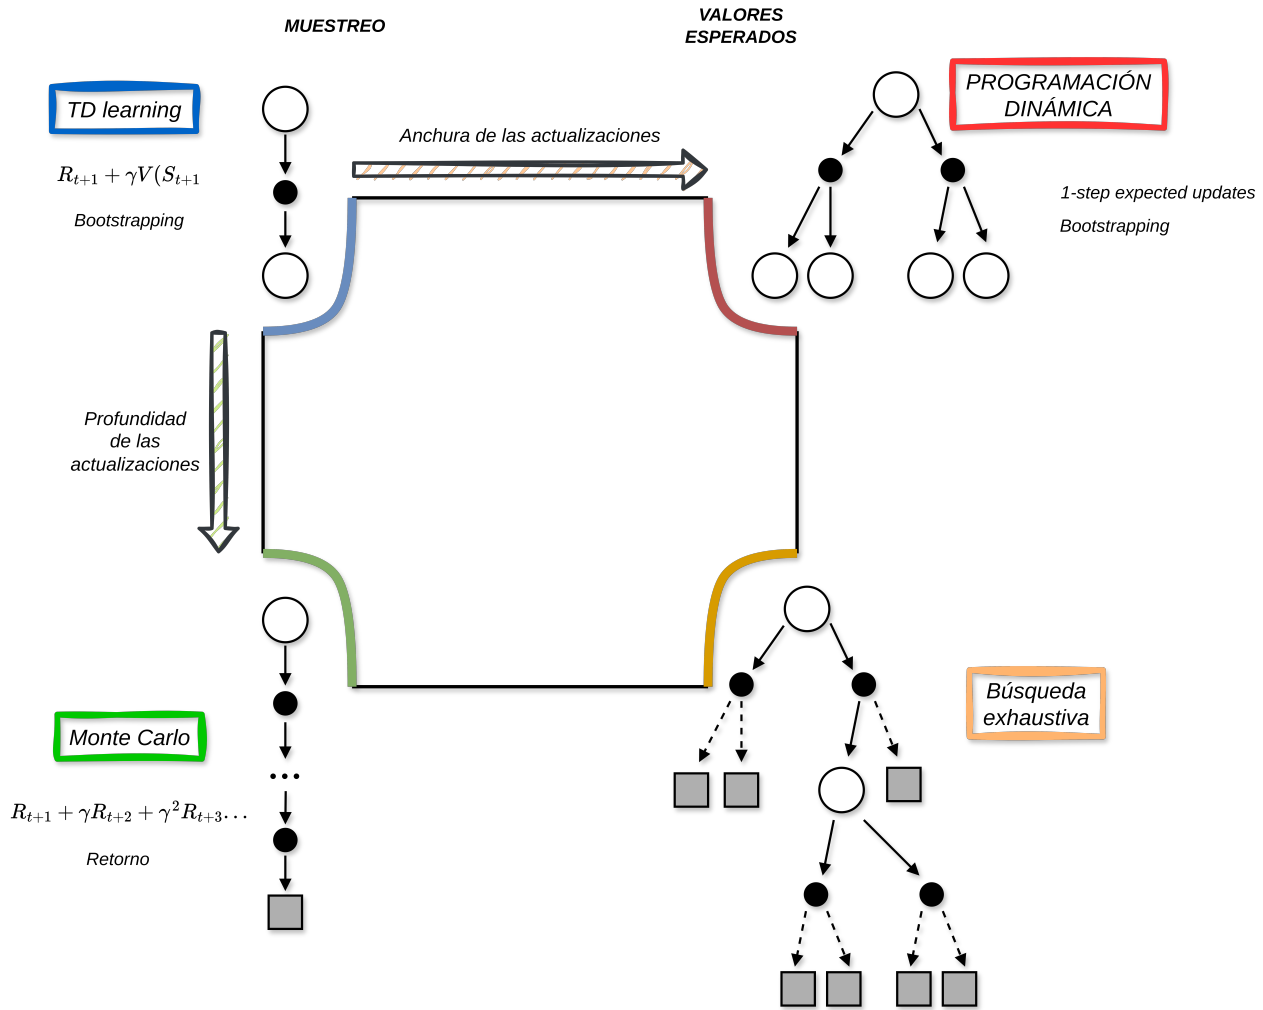
MUESTREO
VALORES ESPERADOS
TD learning
$R_{t+1} + \gamma V(S_{t+1}$
Bootstrapping
Anchura de las actualizaciones
PROGRAMACIÓN DINÁMICA
1-step expected updates
Bootstrapping
Profundidad de las actualizaciones
Monte Carlo
$R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} \dots$
Retorno
Búsqueda exhaustiva

Conceptos clave

Conceptos clave

¿Diferencia entre problemas **episódicos** y **continuados**?

- **Episódicos**: problemas divisibles en episodios con un duración determinada, desde un estado inicial hasta un estado terminal.
- **Continuados**: no existen estados terminales.

Conceptos clave

¿Diferencia entre **estado** y **observación**?

- **Estado**: contiene información **completa** sobre el estado actual del entorno.
- **Observación**: contiene la información **parcial** percibida por el agente. Es un **subconjunto** de la información contenida en el estado.

Diferenciamos entre MDP y POMDP.

Conceptos clave

¿Diferencia entre **valor** y **recompensa**?

- **Valor**: retorno esperado a partir de un estado o par acción–estado.
- **Recompensa**: valor inmediato percibido al alcanzar un estado o realizar una determinada acción desde un estado.

¿Qué es el **retorno**?

Retorno: recompensa acumulada al final de un episodio o secuencia de *time steps*.

Conceptos clave

¿Diferencia entre **exploración** y **explotación**?

- **Exploración**: elección de acciones subóptimas que pueden conducir a nuevas experiencias/transiciones/recompensas no percibidas.
- **Explotación**: aplicación de la política (óptima) actual para maximizar una función de recompensa.

Conceptos clave

¿Diferencia entre **predicción** y **control**?

- **Predicción**: estimación de las funciones de valor para una política dada. Consiste en **evaluar** una política.
- **Control**: encontrar la política óptima que maximice la recompensa acumulada. Implica **evaluación** y **mejora** de la política actual.

Conceptos clave

¿Diferencia entre métodos ***on-policy*** y ***off-policy***?

- ***On-policy***: la política empleada para generar experiencia y aprender es **la misma** que se emplea para actuar.
- ***Off-policy***: una política genera experiencia (**comportamiento**) mientras que otra se emplea para actuar (**objetivo**).

Conceptos clave

¿Diferencia entre ***model-based*** y ***model-free***?

- ***Model-based***: métodos de RL basados en el aprendizaje y/o aprovechamiento de modelos para generar experiencia y **planificar** un comportamiento óptimo.
- ***Model-free***: métodos de RL que no requieren un modelo del entorno y **aprenden directamente** a partir de interacción real.

Conceptos clave

Programación dinámica

- Evaluación de la política.
- Mejora de la política.
- Iteración de la política.
- DP síncrona *vs.* asíncrona.
- Iteración de la política generalizada (GPI).

Bandits

- Exploración *vs.* explotación.
- ε-*greedy*.
- *Upper Confidence Bound*
- *Thompson Sampling*
- Actualizaciones incrementales

Planificación

- Dyna-Q
- Dyna-Q+
- MC *tree search*

Métodos basados en muestreo

- Monte Carlo.
- Inicios de exploración.
- *Importance sampling*.
- *On-policy vs. off-policy*.
- *TD learning*.
- SARSA.
- *Q-learning*.
- *Expected SARSA*.
- Métodos *n-step*.

Limitaciones de los métodos tabulares

Métodos tabulares

Los métodos vistos hasta el momento se denominan **tabulares** debido a la forma en que almacenan y gestionan la información.

Por ejemplo, en el caso de las **políticas**, estas pueden representarse como una **tabla** que relaciona estados y acciones, o estados, acciones y valores.

- Ej. *Q-table*.

*Asumimos que el número de estados y acciones es **discreto** y **limitado**, por lo que su gestión es computacionalmente viable.*

Limitaciones

❓ ¿Pero qué ocurre si el **espacio de estados** / **acciones** es **infinito**?

... o lo suficientemente grande como para ser **inabarcable** por los métodos vistos 🤔

¡Lo veremos en la siguiente parte! 🎊 😀

Aprendizaje por refuerzo

Resumen

Antonio Manjavacas

manjavacas@ugr.es